

# EmoNet: the Emotion Network

신경 활성 추적 기반 감정 상태 표현과 에피소드 조건화에 대한 탐구

EmoNet Working Draft v2 | 2026 년 5 월 4 일

## 초록

본 탐구는 생성형 언어 모델의 공감 응답이 왜 자주 어색하게 느껴지는가라는 문제에서 출발했다. 기존 방식은 감정을 주로 텍스트 라벨, 감정 벡터, 또는 "공감적으로 답하라"는 문체 지시로 다룬다. 그러나 감정은 단순한 이름이나 말투가 아니라, 어떤 자극이 내부에서 어떻게 평가되고, 어떤 경로로 활성화되며, 어떤 행동 경향으로 이어지는지를 포함하는 상태이다. EmoNet 은 이 문제를 해결하기 위해 감정을 외부 라벨이 아니라 내부 신경 활성 흐름으로 다루는 구조를 만들고자 했다.

연구는 v1 부터 v4 까지 단계적으로 발전했다. v1 에서는 입력 문장을 감정/자극 벡터로 바꾸고, 이를 EmotionDynamicsNet 에 통과시킨 뒤 시간별 히스토리와 잠재 상태  $z$  를 관찰하는 첫 파이프라인을 만들었다. v2 에서는 흥분성, 억제성, 조절성 뉴런, trait EMA, cluster, rewiring, branch tracking,  $z \rightarrow s$  회귀, prompt generator, style scorer 를 갖춘 모듈형 구조를 만들었다. v3 에서는 내부 대표 경로인 dominant branch 를 본격적으로 추출했고, branch collapse 와 스타일 목표 편향을 발견했다. v3.1 에서는 감정 정의를 바꾸어, 최초 감정 벡터를 감정이 아니라 자극으로 보고, 그 자극이 뉴런망 안에서 만든 trace 자체를 감정 상태 표현 후보로 정의했다. v4 에서는 trace 를 감정 에피소드로 해석하고, targeted episode-sensitive 입력에서 자극만 사용하는 기준선과 비교했다.


핵심 결과는 다음과 같다. v3 보정 이후 지배 흐름 평균 길이는 1.0539 에서 70.4684 로 증가했고, 한 칸짜리 흐름 비율은 0.9734 에서 0.0948 로 낮아졌다. v3.1 에서는 흐름 길이 50.475, 한 칸짜리 흐름 비율 0.000, 활성 밀도 0.709412, 감정 구조 분리도 0.238547, 균형 보정 감정 신호 0.136426 을 얻었다. 인과 확인 실험에서는 전체 성공률 0.916667 을 얻었다. v4 targeted 조건에서 episode\_trace\_v3 는 stim\_only 대비 paired  $n=78$ , 평균 차이 +1.8308, 95% 부트스트랩 신뢰구간 [+1.5667, +2.0897], 승/무/패 70/3/5 를 보였다. 다만 일반 조건에서는 trace 기반 응답이 항상 우월하지 않았다. 따라서 본 탐구의 결론은 EmoNet 이 모든 감정 응답을 해결했다는 것이 아니라, 신경 활성 trace 가 감정 상태 표현 후보가 될 수 있으며, 에피소드 정보가 필요한 targeted 조건에서 자극만 사용하는 방식보다 감정 에피소드 충실도를 높일 수 있다는 것이다.

## 탐구 동기

이 탐구는 LLM 의 공감 응답이 겉으로는 친절하지만 실제 감정의 핵심을 놓치는 경우가 많다는 문제의식에서 시작했다. 사용자가 분노하거나 상처받은 상황을 말했을 때, LLM 은 대체로 부드럽고 안전한 문장으로 답한다. 그러나 그런 응답은 때로 사건의 불공정함, 모욕감, 수치심, 방어 욕구, 항의 충동 같은 핵심을 너무 일찍 덮어버린다. 그 결과 응답은 공손하지만 감정적으로는 비어 있거나 어색하게 느껴진다.

기존 방식에서는 감정을 주로 세 가지 방식으로 다룬다. 첫째, 문장을 읽고 "분노", "슬픔", "불안" 같은 라벨을 붙인다. 둘째, 긍정-부정, 각성-진정 같은 감정 벡터를 만든다. 셋째, LLM 에게 "공감적으로", "차분하게", "따뜻하게" 답하라고 지시한다. 이 방식들은 유용하지만, 감정이 내부에서 어떻게 생기고 변화하는지는 설명하지 못한다.

본 탐구의 출발점은 감정을 출력 라벨이나 말투가 아니라 내부 상태로 다루자는 생각이었다. 같은 분노라도 공개적 모욕에서 생긴 분노, 불공정한 평가에서 생긴 분노, 자기 실패를 방어하기 위한 분노는 다르다. 이 차이는 라벨 하나로 충분히 표현되지 않는다. 따라서 감정 상태를 이해하려면 자극, 평가, 내부 활성화 경로, 행동 경향, 응답 표면화를 함께 보아야 한다.



*EmoNet 전체 연구 파이프라인과 버전별 역할.*

## 탐구 목적과 핵심 가설

본 탐구의 목적은 감정을 단순한 텍스트 라벨이 아니라, 자극이 내부 신경 동역학 안에서 만든 활성화 흐름으로 표현할 수 있는지 확인하는 것이다. 이를 위해 다음 질문을 세웠다.

1. 입력 문장을 감정/자극 벡터로 바꾸고, 이를 뉴런망 동역학에 통과시켜 내부 잠재 상태를 만들 수 있는가?

2. 자극이 뉴런망 안에서 지나간 대표 경로를 추출하면 감정 상태를 설명하는 중간 표현이 될 수 있는가?
3. 최초 감정 벡터가 아니라 신경 활성화 trace 자체를 감정 상태 표현 후보로 볼 수 있는가?
4. trace 를 에피소드로 해석하면, 감정 원인과 행동 경향이 중요한 입력에서 더 충실한 응답을 만들 수 있는가?

초기 가설은 "감정 벡터를 뉴런망에 통과시켜 얻은 결과 상태가 AI 가 내부적으로 형성한 감정 상태일 수 있다"는 것이었다. 그러나 연구가 진행되면서 이 가설은 바뀌었다. v3.1 이후의 핵심 가설은 다음과 같다.

*초기 감정 벡터는 감정 그 자체가 아니라 자극이며, 감정 상태 표현 후보는 그 자극이 뉴런망 안에서 만든 신경 활성화 trace 이다.*

이 정의 전환이 본 탐구의 중심이다. 감정은 결과 벡터 하나가 아니라, 그 벡터가 만들어지는 동안 어떤 뉴런이 켜지고, 어떤 경로가 유지되고, 어떤 정보가 억제되거나 확산되는지의 과정에 더 가깝다고 보았다.

## 이론적 배경과 기존 방식의 한계

### 감정 라벨의 한계

감정 라벨은 감정을 빠르게 요약하지만, 감정의 내부 구조를 설명하지 못한다. "분노"라는 라벨 안에는 모욕, 배신, 불공정, 좌절, 자기방어가 모두 들어갈 수 있다. 이들은 같은 라벨을 가질 수 있지만 행동 경향은 다르다. 어떤 분노는 즉각 항의로 이어지고, 어떤 분노는 위험 계산 때문에 보류된다.

### 감정 벡터의 한계

감정 벡터는 라벨보다 세밀하지만 여전히 정적인 표현이다. 벡터는 특정 순간의 감정 성분을 나타낼 수 있지만, 그 성분이 어떤 내부 경로로 형성되었는지는 알려주지 않는다. EmoNet 은 이 한계를 넘기 위해 감정 벡터를 최종 결과가 아니라 내부 동역학을 시작하는 자극으로 재해석했다.

### LLM 공감 응답의 한계

LLM 은 자연스러운 공감 문장을 잘 만든다. 그러나 LLM 은 종종 안전하고 부드러운 문체를 선호한다. 이 때문에 감정의 거친 핵심이 지워질 수 있다. 본 탐구에서는 이를 과도한 온건화라고 부른다. EmoNet 은 부드러움을 없애려는 것이 아니라, 안전한 표현 안에서도 원초 정서와 행동 경향을 보존하려 했다.

# EmoNet의 발전 과정

EmoNet 연구 버전의 개념 발전




EmoNet 연구 버전의 개념 발전.

## v1: 감정을 내부 상태로 보내는 첫 파이프라인

v1은 emotion\_z\_pipeline.py와 GUI를 중심으로 구성된 초기 실험선이다. v1의 의미는 감정을 텍스트 라벨로만 예측하지 않고, 입력 문장에서 얻은 정서 자극을 내부 동역학으로 통과시킨 뒤 새로운 잠재 상태로 바꾸려 했다는 데 있다. 이때  $z$ 는 단순한 분류 결과가 아니라, 입력 감정이 뉴런망 안에서 변형된 뒤 남은 내부 상태의 압축 표현으로 해석되었다.

v1: 감정을 출력 라벨이 아니라 내부 동역학을 거친 잠재 상태로 보내는 첫 실행 파이프라인




v1 파이프라인. 입력 문장은 감정/자극 벡터로 변환되고, EmotionDynamicsNet의 시간별 히스토리를 거쳐 잠재 상태  $z$ 로 압축된다.

v1 GUI는 단순 편의 기능이 아니라 관찰 장치였다. 연구자는 입력, 추론 결과,  $z$ , 히스토리 변화를 한 화면에서 확인할 수 있었다. 이 경험은 이후 trace와 branch를 더 자세하게 기록해야 한다는 필요성으로 이어졌다. v1의 성과는 정량 성능보다 감정을 내부 상태로 보낼 수 있는 실행 가능한 첫 파이프라인을 만들었다는 점이다.


## v2: 모듈형 감정 동역학 시스템

v2 는 하나의 스크립트에 가까웠던 v1 구조를 분해 가능한 모듈형 시스템으로 바꾸었다. v2 에는 텍스트에서 4 차원 제어 벡터를 만드는 encoder, 흥분성/억제성/조절성 뉴런을 포함한 dynamics, trait EMA, memory, cluster, cluster-level rewiring, branch tracking, history encoder, z -> s style regression, prompt generator, style scorer 가 포함되었다.



v2 모듈 구조. 모듈 분리가 이후 v3/v3.1/v4 의 진단 실험을 가능하게 했다.

v2 의 강점은 감정 벡터를 단순 회귀 모델에 넣지 않고, 기능이 다른 뉴런 집단에 통과시켰다는 점이다. 흥분성 뉴런은 감정 신호를 확산시키고, 억제성 뉴런은 과활성화를 막으며, 조절성 뉴런은 민감도와 방향을 조정한다. trait EMA 와 memory 는 한 번의 입력만이 아니라 이전 상태의 흔적이 다음 반응에 영향을 주도록 만들었다.




v2 뉴런 타입 구조.

v2 에서 branch tracking 은 처음부터 감정의 본체로 정의된 것은 아니었다. 당시에는 내부 경로를 기록하기 위한 보조 장치에 가까웠다. 그러나 이 장치가 있었기 때문에 v3 에서 dominant branch 를 추출할 수 있었고, branch collapse 라는 결정적 병목도 발견할 수 있었다. 따라서 v2 는 trace-as-emotion 가설의 완성형은 아니지만, 그 가설이 가능해지도록 만든 구조적 기반이었다.

### v3: 지배 흐름과 branch collapse 발견

v3 에서는 내부 대표 경로인 dominant branch 를 본격적으로 추출했다. 파이프라인은 입력 문장을 자극 벡터로 만들고, 클러스터 기반 뉴런망 동역학을 실행한 뒤, tick 별 활성화와 firing edge 를 기록하고, 지배 흐름을 추출한다. 이후 지배 흐름은 잠재 감정 표현  $z$  로 압축되고,  $z$  는 스타일 표현  $s$  로 회귀된다.

v3 의 가장 중요한 발견은 branch collapse 였다. 초기 full export 51,628 개 기준 지배 흐름 평균 길이는 1.0539 였고, 한 칸짜리 흐름 비율은 0.9734 였다. 이는 거의 모든 샘플에서 경로가 한 tick 또는 한 노드 수준으로 끝났다는 뜻이다. 이 상태에서는 지배 흐름을 감정 상태 표현의 근거로 쓰기 어렵다.



*v3 보정 전후의 지배 흐름 붕괴 완화.*

보정 이후 지배 흐름 평균 길이는 70.4684 로 증가했고, 한 칸짜리 흐름 비율은 0.0948 로 감소했다. 이 결과는 응답이 곧바로 좋아졌다는 뜻이 아니라, trace 를 분석 가능한 길이로 회복했다는 뜻이다.

### v3.1: trace-as-emotion 정의 전환

v3.1 에서는 감정 정의가 바뀌었다. 초기 감정 벡터는 감정이 아니라 자극이고, 그 자극이 뉴런망 안에서 만든 신경 활성화 trace 가 감정 상태 표현 후보라는 관점이 중심이 되었다. 이 전환은 EmoNet 전체에서 가장 중요한 개념 변화이다.

### 감정 정의의 변화: 벡터 결과에서 내부 활성 과정으로




### 감정 정의의 변화.

v3.1 은 trace 가 감정 상태 표현 후보인지 확인하기 위해 동역학 지표, 표현 지표, 인과 지표를 사용했다. 단순히 trace 가 길다는 것만으로는 충분하지 않다. trace 는 적절한 활성 밀도와 구조 분리도를 가져야 하고, 감정축 정보가 남아 있어야 하며, 조작했을 때 judge 가 그 차이를 구분할 수 있어야 한다.

### v4: 감정 에피소드 해석과 targeted 평가

v4 에서는 trace 를 감정 에피소드로 해석했다. 에피소드 해석은 감정 이름 하나를 출력하지 않고, 왜 그런 감정이 형성되었는지, 자극이 어떤 평가 구조로 처리되었는지, 행동 경향은 무엇인지, 표면 응답에서 부드러워질 위험은 얼마나 되는지까지 설명한다.

### v4 episode conditioning: trace를 응답 가능한 사건 구조로 번역



### v4 episode conditioning 흐름.

v4 의 중요한 판단은 일반 조건과 targeted 조건을 분리한 것이다. 일반 조건에서는 trace 기반 응답이 자극만 사용하는 기준선을 안정적으로 이기지 못했다. 반면 targeted episode-sensitive 조건에서는 trace 기반 episode 정보가 자극만 사용하는 방식보다 더 높은 에피소드 충실도를 보였다.

## 주요 탐구와 실험

모든 실험의 이전과 이후: 문제, 행동, 의미

| 버전   | 이전 문제/질문        | 행동                  | 이후 의미               |
|------|-----------------|---------------------|---------------------|
| v1   | 감정을 라벨로만 보지 않음  | 내부 동역학+z+GUI        | 내부 상태화 가능성          |
| v2   | 원인 분리 어려움       | 모듈화+뉴런 타입+branch 기록 | 진단 가능한 구조           |
| v3   | branch collapse | reference config 보정 | 흐름 길이 회복            |
| v3.1 | trace가 감정인지 불명확 | 표현 지표+인과 조작         | trace-as-emotion 근거 |
| v4   | 일반 조건 우월성 실패    | targeted episode 평가 | 좁고 방어 가능한 claim     |

모든 실험의 이전과 이후 지도.

### 초기 구조 실험

초기 구조 실험은 입력 문장을 감정/자극 벡터로 바꾸고, 뉴런망 동역학을 거쳐  $z$  를 얻는 것이었다. 이 단계의 성과는 감정 벡터를 뉴런망에 통과시키는 실행 가능한 파이프라인을 만든 것이다. 한계는 감정이 여전히 결과 벡터처럼 취급되었다는 점이다.

### 뉴런 구조와 모듈화 실험

v2 의 목적은 최종 성능을 가장 높이는 것이 아니라, 이후 실험이 가능하도록 구조를 분해하는 것이었다. encoder, dynamics, branching, history encoder, tone regressor, prompt generator, style scorer 가 분리되면서 실패 원인을 모듈별로 진단할 수 있게 되었다.


### branch/dynamics 보정 실험

v3 에서는 branch collapse 를 발견하고, reference config 를 보정했다. 평균 지배 흐름 길이와 한 칸짜리 흐름 비율이 주요 지표였다. 이 실험은 trace 를 감정 상태 표현 후보로 다루기 위한 최소 조건을 회복하는 과정이었다.

### 스타일 편향 분석

v3 에서는 스타일 목표가 긍정성, 부드러움, 차분함, 협조성으로 과도하게 치우쳐 있음을 발견했다. 적대성, 원망, 절망, 불안정성, 두려움, 수치심은 거의 0 에 가까웠다.






v3 스타일 목표 편향.

이 결과는 안전한 챗봇 기준에서는 좋아 보일 수 있지만 EmoNet의 목표와는 충돌한다. 감정 에피소드의 핵심이 분노, 수치심, 두려움, 원망에 있는데 이를 모두 부드럽게 덮으면 감정 상태의 핵심이 사라진다.

## trace 표현 검증

v3.1에서는 trace가 감정측 구조를 담고 있는지 확인했다. n=80 확인 실험에서 감정 흐름 길이는 50.475, 한 칸짜리 흐름 비율은 0.000, 활성 밀도는 0.709412였다. 감정 구조 분리도는 0.238547, 균형 보정 감정 신호는 0.136426이었다.




v3.1 후반부 적응형 활성 조절의 핵심 결과.


## trace 인과 조작 실험

표현 증거만으로는 충분하지 않다. trace 가 감정 상태 표현이라면, trace 의 특정 감정축을 바꿀 때 응답 수준의 감정축 해석도 움직여야 한다. v3.1 은 방향 교란과 강한 정보 중립화를 통해 이를 확인했다.

v3.1 인과 검증 흐름: 관찰 지표에서 조작 가능한 표현으로



v3.1 인과 검증 흐름.




v3.1 축 전용 눈가림 인과 확인 실험.


통합 confirm10 결과에서 전체 성공률은 0.916667, 강한 정보 중립화는 0.975000, 방향 교란은 0.775000, 동일 응답 무효 비교 tie 비율은 1.000000 이었다.

## episode 응답 생성 및 targeted 비교

v4에서는 trace를 감정 에피소드로 해석한 뒤 응답 조건으로 사용했다. 일반 조건에서는 trace 기반 응답이 항상 우월하지 않았다. 그러나 targeted episode-sensitive set에서는 episode\_trace\_v3가 stim\_only보다 뚜렷하게 우세했다.



v4 targeted episode-sensitive 입력에서의 조건별 점수.



v4 상대 우월성 평가.

## 평가 지표

EmoNet 지표 체계: trace가 생겼는지, 의미가 있는지, 응답에 도움이 되는지

| 동역학 지표   | 표현 지표     | 인과 지표      | 생성 지표  |
|----------|-----------|------------|--------|
| 흐름 길이    | 구조 분리도    | 방향 교란      | 평가 충실도 |
| 한 칸짜리 비율 | 균형 보정 신호  | 정보 중립화     | 원초 정서  |
| 활성 밀도    | 축별 정보     | 축 전용 judge | 온건화 방지 |
| 늦은 점화    | trace 안정성 | 성공률        | 행동 경향  |

*EmoNet 지표 체계.*

### 동역학 지표

동역학 지표는 trace가 감정 상태 표현으로 쓸 수 있을 만큼 살아 있는지를 판단한다. 주요 지표는 감정 흐름 길이, 한 칸짜리 흐름 비율, 활성 밀도, 최대 tick 도달 비율, 첫 활성 tick, 활성 창 길이이다.

### 표현 지표

표현 지표는 trace가 감정축 구조를 담고 있는지 본다. v3.1에서는 감정가, 사회적 방향, 행동 경향, 평가 계열, 통제감 상태 같은 축을 사용했다. 중요한 점은 단순 정확도가 아니라 데이터 불균형을 고려한 균형 보정 신호를 보았다는 것이다.

### 인과 지표

인과 지표는 trace 조작이 응답의 감정축 해석을 움직이는지 본다. 방향 교란은 특정 축 값을 다른 방향으로 바꾸고, 정보 중립화는 특정 축 단서를 neutral로 바꾼다. 축 전용 눈가림 judge는 helpfulness, warmth, politeness, fluency, empathy, general quality를 판단하지 못하게 하고 target emotion axis만 보도록 설계되었다.

### 생성 지표

생성 지표는 일반 응답 품질과 targeted episode-fidelity로 나뉜다. targeted 지표는 상황 평가 충실도, 원초 정서 반영, 과도한 온건화 방지, 행동 경향 적합도, 구체성, 자연스러움, 전체 선호를 본다.

## 탐구 결과

### 내부 상태화 파이프라인의 성립

v1/v2 의 결과는 최종 성능 우월성이 아니라 구조적 성립이다. 감정을 라벨로 바로 출력하지 않고, 입력 자극을 내부 동역학으로 보내고, 히스토리와  $z$  를 관찰하며, 모듈별로 분해 가능한 구조를 만들었다.

### branch collapse 완화

v3 보정 이후 지배 흐름 평균 길이는 1.0539 에서 70.4684 로 늘었고, 한 칸짜리 흐름 비율은 0.9734 에서 0.0948 로 낮아졌다. 이는 trace 분석을 위한 최소 동역학 조건이 회복되었음을 의미한다.

### trace 표현 검증


v3.1 의 최종 적응형 설정은 흐름 길이, 활성 밀도, 구조 분리도, 균형 보정 감정 신호를 동시에 만족했다. 이는 trace 가 단순 로그가 아니라 감정축 구조를 일부 담고 있음을 보여준다.

### 인과 조작 결과


방향 교란과 강한 정보 중립화 실험은 trace 가 조작에 반응한다는 초기 증거를 제공했다. 동일 응답 무효 비교가 40/40 tie 였다는 점은 judge 가 억지로 차이를 만든 것이 아님을 보여준다.

### 일반 조건 실패와 targeted 조건 성공

v4 일반 조건에서는 episode\_trace 가 stim\_only 보다 우세하지 않았다. episode\_trace vs stim\_only 의 평균 차이는 -0.081416 이었고 신뢰구간은 0 을 포함했다. 반면 targeted 조건에서는 episode\_trace\_v3 가 stim\_only 보다 평균 차이 +1.8308, 승/무/패 70/3/5 로 우세했다.



일반 조건과 targeted 조건의 이전/이후 비교.



targeted 조건에서 지표별 향상량.

## 논의

### 감정 벡터 중심 관점에서 trace 중심 관점으로

EmoNet의 핵심 변화는 감정을 결과 벡터로 보던 관점에서 trace로 보던 관점으로 이동한 것이다.

v1/v2에서는 감정 벡터가 뉴런망을 통과해 변형된 결과를 감정 상태처럼 해석했다. v3.1에서는 이 관점을 바꾸어 초기 벡터를 자극으로 보고, 그 자극이 내부에서 만든 활성화 trace를 감정 상태 표현 후보로 보았다.

### 실패가 연구를 어떻게 바꾸었는가

branch collapse, 스타일 목표 편향, 일반 조건 비우월성은 모두 실패였지만, 동시에 다음 실험의 이유가 되었다. branch collapse 때문에 동역학 지표가 생겼고, 스타일 편향 때문에 anti-softening 지표가 생겼으며, 일반 조건 실패 때문에 targeted claim으로 좁혔다.


### LLM judge 편향과 대응

LLM judge는 부드럽고 자연스러운 답변을 선호할 수 있다. 본 탐구는 이 문제를 인식하고 축 전용 눈가림 judge를 만들었다. 그러나 LLM judge만으로 충분하지 않다. 향후 사람 평가와 다중 judge 비교가 필요하다.

## EmoNet 이 실제로 만든 것

EmoNet 은 단순히 더 긍정적인 응답 생성기를 만든 것이 아니다. 오히려 기존 LLM 응답이 긍정성과 부드러움으로 기울어지는 문제를 드러냈고, 내부 trace 와 episode 정보를 사용해 특정 조건에서 그 편향을 줄일 수 있음을 보였다.

## 한계와 주장 가능 범위



현재 주장 가능 범위와 아직 주장하면 안 되는 범위.

현재 주장 가능한 것은 다음이다. v3 보정 이후 branch collapse 가 완화되었다. v3.1 trace 는 감정축 정보를 일부 담고 조작에 반응했다. v4 targeted 조건에서는 episode trace 가 자극만 사용하는 기준선보다 에피소드 충실도를 높였다.

아직 주장하면 안 되는 것도 분명하다. EmoNet 이 인간처럼 실제 감정을 느낀다고 주장할 수 없다. 모든 일반 감정 응답에서 항상 우수하다고 주장할 수 없다. LLM judge 결과만으로 사람 평가를 통과했다고 볼 수 없다. v1/v2 의 정량 지표도 아직 충분하지 않다.

## 향후 탐구

향후 탐구는 다섯 방향으로 진행되어야 한다. 첫째, 사람 평가를 통해 LLM judge 편향을 검증해야 한다. 둘째, v1/v2 의 정량 실험과 GUI 스크린샷을 보강해야 한다. 셋째, 흥분성, 억제성, 조절성 뉴런을 제거하는 ablation 실험을 해야 한다. 넷째, trace 인과 검증을 더 큰 규모로 확장해야 한다. 다섯째, 장기 감정 상태와 episode memory 를 도입해 반복 상호작용에서 감정 상태가 어떻게 변하는지 보아야 한다.

## 결론

본 탐구는 LLM 공감 응답의 어색함에서 출발해, 감정을 출력 라벨이나 문체가 아니라 내부 신경 활성화 trace 로 다루는 EmoNet 구조를 만들었다. v1 은 감정을 내부 상태로 보내는 첫 파이프라인이었고, v2 는 모듈형 뉴런망과 branch 기록을 만들었다. v3 는 dominant branch 를 추출하며 branch collapse 와 스타일 편향을 발견했다. v3.1 은 감정 정의를 바꾸어 trace 자체를 감정 상태 표현 후보로 보았다. v4 는 trace 를 episode 로 해석하고 targeted 조건에서 응답 충실도 향상을 확인했다.

최종적으로 EmoNet 은 모든 감정 응답을 해결한 완성형 시스템이 아니다. 그러나 자극을 내부 신경 활성화 흐름으로 전개하고, 그 흐름을 감정 상태 표현 후보로 분석하며, targeted episode-sensitive 조건에서 자극만 사용하는 기준선보다 감정 에피소드 충실도를 높일 수 있음을 보였다. 이것이 현재 가장 방어 가능한 결론이다.

## 부록


### 핵심 용어

| 용어      | 의미                                                             |
|---------|----------------------------------------------------------------|
| 자극      | 입력 문장이 내부 동역학에 가하는 최초 압력. v3.1 이후 초기 감정 벡터는 감정이 아니라 자극으로 해석된다. |
| trace   | 자극이 뉴런망 안에서 만든 시간적 활성화 기록. 감정 상태 표현 후보이다.                      |
| 지배 흐름   | trace 에서 추출한 대표 경로.                                            |
| 감정 에피소드 | trace 를 사건 원인, 평가 구조, 원초 정서, 행동 경향으로 해석한 중간 표현.                |
| 과도한 온건화 | LLM 응답이 감정의 거친 핵심을 지나치게 부드럽게 덮는 현상.                            |



## 모듈과 증거의 연결

모듈과 증거의 연결: 각 행동에는 대응 지표가 있어야 한다



모듈과 증거의 연결.

## 참고 자료

## 참고 자료

EmoNet v2 README. 모듈형 PyTorch MVP 설명 문서. 2026.

EmoNet v3 Korean Draft. 감정 동역학 기반 한국어 응답 생성 프레임워크. 2026.

Branch Collapse Mitigation. v3 branch length collapse 분석 및 완화 기록. 2026.

v3.1 Final Completion Report. trace-as-emotion 표현 및 인과 검증 보고서. 2026.

EmoNet v4 Research Summary. episode interpretation 및 generation 평가 요약. 2026.

EmoNet Targeted Superiority Report. targeted episode-sensitive 입력에서의 쌍대 우월성 평가. 2026.